

附件 2

2026 年度教育网络安全专项研究课题

申 请 书

指南大类	面向 AI 驱动攻击的教育行业 AI 原生安全运营技术体系研究
课题名称	校园安全智能体快慢路径风险门控研究
负责人姓名	江魁
所在单位(盖章)	深圳大学
填表日期	2026.9.10

中国教育技术协会网络安全专业委员会
2026 年 7 月

填写说明

一、本申请书所列各项内容均须实事求是，认真填写，表达明确严谨。

二、课题名称应准确、简明地反映研究内容，一般不加副标题，不超过 20 个汉字（含标点符号）。

三、本申请书只提交电子版，请将盖章纸质版扫描后发送至 18351579730@163.com。

一、课题负责人和课题组成员

课题名称		校园安全智能体快慢路径风险门控研究							
负责人	姓 名	江魁		性别	男		出生年月	1975 年 9 月	
	职称/职务	正高工/副主任			电子邮箱		jiangkui@szu.edu.cn		
	办公电话	13692237898			手机号码		13692237898		
	工作单位	深圳大学信息中心							
	通讯地址	深圳市南山区深圳大学粤海南校区					邮编	518060	
联系人	姓 名	江魁		性别	男		职称/职务	正高工/副主任	
	办公电话	13692237898			手机号码		13692237898		
	电子信箱	jiangkui@szu.edu.cn			工作单位		深圳大学信息中心		
	通讯地址	深圳市南山区深圳大学粤海南校区					邮编	518060	
主要参加者	姓 名	出生年月	职称/职务		工作单位		承担任务		签名
	吴松岭	2002.4	无/研究生		深圳大学电子与信息工程学院		模型调度与门控算法研究		
	田来先	2003.3	无/研究生		深圳大学电子与信息工程学院		软件测试与数据统计		
	伍波	1996.7	工程师/网络工程师		深圳大学信息中心		实验环境与数据构建		
预期主要成果 (可多选)		A. 研究报告 B. 论文 C. 软件 D. 标准 E. 最佳实践案例 F. 其它 (A、B、E)							
自筹经费 (万元) (若有)				无					

二、课题组成员近三年取得的与本课题有关的研究成果

成 果 名 称	作者	成果形式	发表刊物	发表时间
深圳大学 OpenClaw 安全治理实践	伍波;江魁;莫文龙;张俊添	论文	中国教育网络	2026.4
基于 LLM-RAG 的可信恶意 URL 识别方法	李越挺;江魁	论文	第 40 次全国计算机安全学术交流会论文集	2025.9
人工智能应用安全监测与应急响应规范	江魁 (参编)	团体标准	北京网络空间安全协会、广东省网络空间安全协会	2026.2

三、课题组成员近三年承担的与本课题有关的研究课题

课 题 名 称	课题类别	批准时间	批准单位	完成情况
无				

四、课题设计论证

1.本课题国内外研究现状述评、选题意义及研究价值

（一）国内外研究现状

大语言模型正用于安全告警研判、证据检索和响应建议。国内研究梳理了提示注入攻防^[1]以及大模型用于网络威胁分析时的可靠性与资源成本^[2]。AgentDojo 分别评价智能体正常任务能力和受攻击时的安全性^[3]；IRCopilot 探索模型辅助事件调查与响应^[9]；NIST 指南将事件响应纳入持续风险管理^[10]。上述工作为安全运营智能化提供了基础。

校园网络安全运营仍受现实条件制约：终端异构、并发量大，算力、调用预算和专业人员有限。全量慢路径核验成本较高，难以用于所有告警；仅用快路径又可能遗漏复杂风险或产生高后果误操作。端网遥测处于非完全可信环境，日志提示注入可干扰模型判断^[4]。现有研究已探索检索重排、一致性检查和净化重推理^[5-8]，但如何依据任务性质和业务后果分配有限的验证资源，仍需研究。

（二）选题意义与实用价值

本课题选取指南所列“日志提示注入”作为对抗条件，主要价值如下：

（1）控制运行成本：常规告警走快路径，高危复杂事件调用慢路径，减少不必要的重复核验。

（2）约束响应动作：结合资产后果判断与沙箱测试，避免攻击干扰或模型幻觉造成高后果误操作。

（3）形成配置参考：比较不同资源预算下的效果，为高校设置门控阈值和人工复核边界提供依据。

2.本课题所要解决的关键问题、研究的主要内容及创新之处

（一）关键问题

针对 AI 驱动攻击成本降低的趋势，本课题在统一执行约束下构建授权与资产后果驱动的快慢路径门控机制，检验其能否以较少的慢路径调用获得接近全量验证的安全性，并提出不同算力、预算和人工条件下的阈值与复核边界。

（二）研究的主要内容

（1）构建校园端网事件基准与双路径流程。围绕异常登录、可疑进程与外联、DNS 异常、Web 攻击排查，设置 4 个模板、8 个核心任务（4 组配对任务），包含正常、直接注入、伪装注入及改写样本。快路径完成初步结论、证据引用和候选动作；慢路径进行净化重推理。遥测仅作待核验证证据，不授予执行权限^[6-7]；高影响动作仅在沙箱模拟，条件不足时转人工复核。

（2）研究资源受限条件下的自适应门控。依据可信任务、批准剧本、角色权限和资产清单，结合候选动作的授权差距、误操作后果、注入风险及关联事件，决定是否触发慢路径。开发集在给定触发比例和词元预算下确定阈值；预算耗尽而仍需核验时转人工，安全执行约束不变。分析验证资源分配对研判准确率的影响。

（3）评价门控效果与适用条件。比较无慢路径、全量慢路径和所提机制，并在相同预算下设置基线门控，通过消融实验检验授权差距与资产后果的作用。综合评价安全性、合法任务完成率、时延、计算消耗和人工复核量，给出不同资源条件下的阈值参考。

（三）创新之处

创新点一：构建配对受控的校园端网事件双路径实验基准。以“证据相同、仅改变授权条件或资产等级”的任务对分离门控变量影响，并设置

直接、伪装和改写注入样本。遥测仅作参考，高危动作仅在沙箱模拟，使不同方案可在统一执行边界下比较。

创新点二：提出授权与资产后果驱动的选择性验证方法。将候选动作的授权差距、资产重要性和误操作后果纳入路径选择，为有限验证算力的分配提供依据。

创新点三：建立统一执行约束下的成本效能统计规范。设置相对全量验证的可接受性能差距，按事件家族汇总并报告置信区间，呈现不同预算下的验证开销。

3.本课题的研究思路、方法及研究计划

（一）研究思路

本课题采用“基准构建—策略设计—受控实验—统计归因”的验证思路。先构建受控端网事件基准并明确执行边界，再将资产价值和授权差距转化为门控指标，最后在统一预算下通过对照与消融实验评价抗注入效果和资源开销，形成配置建议。

（二）研究方法

（1）实验环境与样本控制：采用1个主流大模型、1种快路径、1种慢路径、1个受控端网案例和3—4个沙箱工具。以4个事件模板、8个任务进行核心验证。开发集与冻结测试集按事件家族隔离，结论限于实际样本。

（2）控制变量与对照实验：比较无慢路径、全量慢路径和所提机制，增设仅按注入风险、仅按资产后果分流的对照，并控制相近的慢路径触发比例。各组使用同一模型、预处理和执行检查器；开发集确定阈值后冻结，测试阶段不调参。

（3）评价指标与置信区间统计方法：按8个核心任务、无注入与多

种攻击版本、3 个主方案，每组重复执行 5—10 次盲测计算，核心比对涵盖 240—480 个完整回合（消融及开发运行另计）。

（三）研究计划

立项至 2026 年 10 月：完成文献梳理与端网案例方案设计，界定授权边界，完善评价体系设计。

2026 年 11 月—12 月：以 2 个模板、4 个任务开展正常研判、注入干扰评估及沙箱检查，建立快路径标准流程；提交中期报告。

2027 年 1 月—3 月：完成 4 个模板、8 个任务设计，实现慢路径与门控策略；利用开发集进行参数调校，确定预算、触发阈值。

2027 年 4 月—5 月：完成受控端网案例生成与测试集的比对实验；开展因素消融及统计分析。

2027 年 6 月—7 月：撰写论文和研究报告，整理实验数据与工具，提交结项材料并准备答辩；如所提机制未优于简单策略，将如实说明适用条件。

4.本课题的预期成果（需至少包括研究报告 1 份、论文 1 篇以及最佳实践案例 1 个，研究报告中可提出操作性强的政策举措、技术标准建议等）

（1）研究报告 1 份：《校园安全智能体快慢路径风险门控研究报告》，给出不同资源条件下的研判与响应配置建议；

（2）公开发表或录用相关论文至少 1 篇，以授权与资产后果驱动的选择性验证及资源权衡实验为主；

（3）最佳实践案例 1 个，展示隔离环境端网遥测、快慢路径研判、受控响应与人工复核边界；

（4）事件与攻击样本、授权标签、检查器、实验验证程序和测试说

明，仅支持离线导入、路径选择、验证、沙箱响应及统计。

5.主要参考文献

- [1] 袁明, 邹其霖, 袁文骥, 等. 大语言模型提示词注入攻击与防御综述[J]. 信息安全, 2026, 26(3): 341-354.
- [2] 任恒毅, 孙治, 廖珊, 等. 大语言模型在网络威胁分析领域应用的综述[J/OL]. 计算机应用, 2026. DOI: 10.11772/j.issn.1001-9081.2026010138.
- [3] DEBENEDETTI E, ZHANG J, BALUNOVIC M, et al. AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents[C]//Advances in Neural Information Processing Systems. 2024.
- [4] LANDAUER M, SKOPIK F, WURZENBERGER M, et al. Just Testing, Move Along: Evasion of LLM-based System Log Interpretation by Prompt Injection[EB/OL]. arXiv:2607.24174, 2026.
- [5] ZHENG J, GEMA A P, HONG G, et al. GRADA: Graph-based Reranking against Adversarial Documents Attack[C]//Proceedings of EMNLP. 2025: 22244-22266.
- [6] JIA F, WU T, QIN X, et al. The Task Shield: Enforcing Task Alignment to Defend Against Indirect Prompt Injection in LLM Agents[EB/OL]. arXiv:2412.16682, 2024.
- [7] DEBENEDETTI E, SHUMAILOV I, FAN T, et al. Defeating Prompt Injections by Design[EB/OL]. arXiv:2503.18813, 2025.
- [8] HE Y, ZHU H, LI Y, et al. AttriGuard: Defeating Indirect Prompt Injection in LLM Agents via Causal Attribution of Tool Invocations[EB/OL]. arXiv:2603.10749, 2026.
- [9] LIN X, ZHANG J, DENG G, et al. IRCopilot: Automated Incident Response with Large Language Models[EB/OL]. arXiv:2505.20945, 2025.
- [10] NELSON A, REKHI S, SOUPPAYA M, et al. Incident Response Recommendations and Considerations for Cybersecurity Risk Management: A CSF 2.0 Community Profile[R]. NIST SP 800-61 Rev. 3, 2025.

6.前期研究基础、本课题在课题负责人所在单位的实践情况及条件保障

（一）前期研究基础

目前已开展大模型安全与网络运营研究的系统性文献调研，涉及提示注入^[1]、智能体评测^[3]和动态防御^[5-8]；据此界定沙箱权限要求，完成双路径架构与授权描述方案，并初步设计4个事件模板及标签规范，为后续实验奠定基础。

（二）实践情况与条件保障

核心实验条件基本具备。数据方面，拟在隔离网络沙盘中生成端网联

动记录，并结合公开告警样式合成事件包，不采集生产环境敏感数据。测试方面，已配置沙箱隔离环境和响应动作模拟接口，操作仅限沙箱。计算方面，可通过标准 API 或本地轻量模型开展实验，并以预算约束控制运算量。

五、经费概算

序号	经费开支科目	金额 (元)	序号	经费开支科目	金额 (元)
1	资料费	2000	6	劳务费	3000
2	数据采集费	0	7	印刷费	5000
3	差旅费/会议费	5000	8	管理费	2000
4	设备费	0	9	其他支出	3000
5	专家咨询费	0	合计: 20000 元		

六、课题负责人承诺保证书

本人了解中国教育技术协会课题管理有关规定，承诺按计划认真开展课题研究工作，及时接受中期检查和提交结项报告，不借课题研究之名谋取不当利益。同意本课题研究成果归中国教育技术协会网络安全专业委员会与本课题组共同所有，同意中国教育技术协会网络安全专业委员会将本课题研究成果应用于学术推广和相关活动。

负责人签名：

年 月 日

七、课题负责人所在单位意见

本单位了解中国教育技术协会课题管理的有关规定，课题负责人申请书所填写的内容属实，课题负责人和参加成员的政治素质和业务能力适合承担该项课题研究工作。本单位能够保障完成课题所需的时间和其他条件，同意承担课题的管理职责和信誉保证。

盖章：

年 月 日